Εθνικο & Καποδιστριακο Πανεπιστημιο Αθηνων
Τμημα Πληροφορικης & Τηλεπικοινωνιων
Μαθημα: **Αρχιτεκτονικη Υπολογιστων ΙΙ**

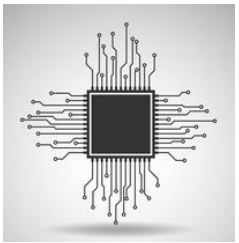

# Εργασία 2 (*υποχρεωτική*) – Κρυφές Μνήμες

**Ακαδημαϊκο Ετος 2024 – 2025**
(εκφωνηση) Τριτη 3 Δεκεμβριου 2024
(παραδοση στο eclass μεχρι) **Δευτερα 23 Δεκεμβριου 2024**



| Επώνυμο – Όνομα | Πατρώνυμο – Μητρώνυμο | Αριθμός Μητρώου | Email |
|---|---|---|---|
| Καραπροδρομίδης Ιάσονας | - | 1115202200064 | iaskarapro@gmail.com |
| Ζορμπά Αλεξάνδρα | - | 1115202200048 | alexandra.n.zorba@gmail.com |



**Πληροφορίες για τις Υποχρεωτικές Εργασίες του μαθήματος**

- Οι υποχρεωτικές εργασίες του μαθήματος είναι **δύο**. Σκοπός τους είναι η κατανόηση των εννοιών του μαθήματος με χρήση αρχιτεκτονικών προσομοιωτών. Η πρώτη υποχρεωτική εργασία αφορά τη διοχέτευση (pipelining) και η δεύτερη (αυτή) αφορά τις κρυφές μνήμες (cache memories).
- Οι δύο εργασίες είναι υποχρεωτικές και η βαθμολογία του μαθήματος θα προκύπτει από το γραπτό (60%), την εργασία της διοχέτευσης (20%), και την εργασία των κρυφών μνημών (20%).
- Κάθε ομάδα μπορεί να αποτελείται **από 1 έως και 2 φοιτητές** (**η υποβολή να γίνει μόνο από έναν φοιτητή εκ μέρους όλης της ομάδας – μην κάνετε υποβολές όλοι**). Συμπληρώστε τα στοιχεία των μελών της ομάδας στον παραπάνω πίνακα. Τα μέλη της ομάδας πρέπει να έχουν ισότιμη συμμετοχή και να γνωρίζουν τις λεπτομέρειες της υλοποίησης.
- Για την εξεταστική Σεπτεμβρίου δεν θα δοθούν άλλες εργασίες. Το Σεπτέμβριο εξετάζεται μόνο το γραπτό.
- Σε περίπτωση αντιγραφής θα μηδενίζονται όλες οι ομάδες που μετέχουν σε αυτή.
- Η παράδοση της **Εργασίας Κρυφών Μνημών** πρέπει να γίνει **ηλεκτρονικά μέχρι τα μεσάνυχτα της προθεσμίας και μόνο στο eclass** (να ανεβάσετε ένα μόνο αρχείο zip ή rar με την τεκμηρίωσή σας σε PDF και τους κώδικές σας). **Μην περιμένετε μέχρι την τελευταία στιγμή – κάθε εργασία απαιτεί τον χρόνο της**.

**Ζητούμενο**

Το ζητούμενο της εργασίας είναι η **αξιολόγηση της ιεραρχίας μνήμης** επεξεργαστών MIPS για συγκεκριμένες υπολογιστικές εργασίες με βάση το **μοντέλο Roofline** (γραμμή στέγης) όπως το είδαμε στο Κεφάλαιο 6 του COD6e. Η σχεδίαση του υλικού και του λογισμικού και η αξιολόγηση θα γίνει στον προσομοιωτή QtMips.

Οι υπολογιστικές εργασίες είναι: **(α) πολλαπλασιασμός διανύσματος n στοιχείων επί βαθμωτό, (β) πολλαπλασιασμός τετραγωνικού πίνακα nxn επί βαθμωτό, (γ) πολλαπλασιασμός δύο τετραγωνικών πινάκων nxn**. Για κάθε εργασία, οι αρχικοί πίνακες και τα αποτελέσματα θα βρίσκονται στο τμήμα δεδομένων του προγράμματος. Να εξετάζεται το ενδεχόμενο υπερχείλισης κατά τη διάρκεια εκτέλεσης των πράξεων και το πρόγραμμα να τερματίζει εάν συμβεί υπερχείλιση. Τα στοιχεία των πινάκων είναι ακέραιοι αριθμοί. Να παρουσιάσετε τα αποτελέσματα της μελέτης σας **για τις τιμές n=8, 16, 32 και προαιρετικά για μεγαλύτερες δυνάμεις του 2**.

Για τη χρήση του μοντέλου Roofline ως «απόδοση» να χρησιμοποιήσετε το **πλήθος των πολλαπλασιασμών ανά δευτερόλεπτο** (MPS – multiplications per second) Ως αριθμητική ένταση (arithmetic intensity) να χρησιμοποιήσετε τον λόγο **πολλαπλασιασμοί ανά byte** (MPB – multiplications per byte).

Τα συστήματα MIPS που θα αξιολογήσετε είναι:

**MIPS-A**: διοχέτευση πέντε σταδίων με πλήρη μονάδα κινδύνων με ανίχνευση και προώθηση και branch predictor των 2-bit με BHT που προσπελάζεται με 5 bit και επίλυση των διακλαδώσεων στο στάδιο EX. Δεν διαθέτει καθόλου κρυφή μνήμη, έχει ρυθμό ρολογιού 100 MHz, και η προσπέλαση της κύριας μνήμης διαρκεί 60 κύκλους ρολογιού.

**MIPS-B**: διοχέτευση ίδια με την παραπάνω, αλλά το σύστημα μνήμης περιέχει και κρυφή μνήμη ενός επιπέδου με μέγεθος 8KB για εντολές και ξεχωριστά 8KB για δεδομένα. Μπορείτε να επιλέξετε το μέγεθος μπλοκ της καθεμίας μεταξύ 2, 4, και 8 λέξεων και τη συσχετιστικότητα τους μεταξύ 1, 2, και 4 (πολιτική αντικατάστασης LRU όπου απαιτείται). Η πολιτική εγγραφής να είναι ετερόχρονη (write back) και με κατανομή σε εγγραφή (write allocate). Ο ρυθμός ρολογιού του επεξεργαστή παραμένει σταθερός και το ίδιο ο χρόνος προσπέλασης της κύριας μνήμης.

**MIPS-Γ**: διοχέτευση ίδια με τους παραπάνω, και πρώτο επίπεδο κρυφής μνήμης όπως ο προηγούμενος. Διαθέτει όμως και δεύτερο επίπεδο κρυφής μνήμης με μέγεθος 64KB ενιαία για εντολές και δεδομένα. Μπορείτε να επιλέξετε το μέγεθος μπλοκ μεταξύ 2, 4, και 8 λέξεων και τη συσχετιστικότητα μεταξύ 1, 2, και 4 (πολιτική αντικατάστασης LRU όπου απαιτείται). Η πολιτική εγγραφής να είναι ετερόχρονη (write back) και με κατανομή σε εγγραφή (write allocate). Η προσπέλαση του δεύτερου επιπέδου κρυφής μνήμης διαρκεί 6 κύκλους ρολογιού. Ο ρυθμός ρολογιού του επεξεργαστή παραμένει σταθερός και το ίδιο ο χρόνος προσπέλασης της κύριας μνήμης.

Να συμπληρώσετε τον παρακάτω πίνακα με **τις σχεδιαστικές αποφάσεις σας** για τις κρυφές μνήμες κάθε επεξεργαστή που διαθέτει τέτοιες.

| **Χαρακτηριστικό** | **MIPS-A** | **MIPS-B** | **MIPS-Γ** |
|---|---|---|---|
| L1 caches μέγεθος μπλοκ (2, 4, 8 λέξεις) | - | 8 λέξεις | 8 λέξεις |
| L1 caches συσχετιστικότητα (1, 2, 4) | - | 1 | 1 |
| L2 cache μέγεθος μπλοκ (2, 4, 8 λέξεις) | - | - | 8 λέξεις |
| L2 cache συσχετιστικότητα (1, 2, 4) | - | - | 1 |

Για κάθε CPU **να σχεδιάσετε τα διαγράμματα Roofline** και το σημείο που βρίσκονται σε αυτά οι υπολογιστικές εργασίες για τις διάφορες τιμές της παραμέτρου n. Να σχολιάσετε τις συμπεριφορές που παρατηρείτε και πιθανές βελτιώσεις του κάθε συστήματος για τις συγκεκριμένες υπολογιστικές εργασίες.

**Τεκμηρίωση**

[ Σύντομη τεκμηρίωση της λύσης σας ενδεικτικά (όχι αυστηρά) μέχρι **10 σελίδες ξεκινώντας από την επόμενη σελίδα** – μην αλλάζετε τη μορφοποίηση του κειμένου (**και παραδώστε την τεκμηρίωση σε αρχείο PDF**). Η τεκμηρίωσή σας πρέπει να περιλαμβάνει παραδείγματα εκτέλεσης και σχολιασμό για την επίλυση του προβλήματος και την επίτευξη του ζητούμενου. Μπορείτε να χρησιμοποιήσετε εικόνες, διαγράμματα και ό,τι άλλο μπορεί να βοηθήσει στην εξήγηση της δουλειάς σας. ]

Για την υλοποίηση της εργασίας μας κατασκευάσαμε 3 προγράμματα ProgramA.s, ProgramB.s, ProgramC.s τα οποία παρατίθενται. Αφού τα κατασκευάσαμε τρέξαμε κάθε ένα από αυτά πολλές φορές, μία για κάθε νόμιμο configuration. Ο MIPS A δεν είχε ενεργοποιημένες τις cache, ο MIPS B είχε ενεργοποιημένη την L1 program cache και L1 data cache και τέλος, ο MIPS C είχε ενεργοποιημένες τόσο τις 2 L1 caches που προαναφέρθηκαν, όσο και την L2 cache. Ακολουθούν τα νόμιμα configurations:

| | **Number of sets** | **Degree of Associativity** | **Block Size** |
|---|---|---|---|
| **L1 Program Cache / L1 Data Cache** | 4096 | 1 | 2 |
| | 2048 | 2 | 2 |
| | 1024 | 4 | 2 |
| | 2048 | 1 | 4 |
| | 1024 | 2 | 4 |
| | 512 | 4 | 4 |
| | 1024 | 1 | 8 |
| | 512 | 2 | 8 |
| | 256 | 4 | 8 |
| **L2 Data Cache** | 32768 | 1 | 2 |
| | 16384 | 2 | 2 |
| | 8192 | 4 | 2 |
| | 16384 | 1 | 4 |
| | 8192 | 2 | 4 |
| | 4096 | 4 | 4 |
| | 8192 | 1 | 8 |
| | 4096 | 2 | 8 |
| | 2048 | 4 | 8 |

Από τις πρώτες παρατηρήσεις μας ήταν πως μονάχα το block size και το n (μέγεθος πίνακα) επηρέαζαν τις εκτελέσεις και όχι η αυξομείωση της συσχετιστικότητας σε βάρος/όφελος του πλήθους των sets. Για να αποφασίσουμε, επομένως, για το ποιο configuration θα χρησιμοποιήσουμε για κάθε μία από τις 3 υλοποιήσεις (n = 8, 16, 32) των 3 προγραμμάτων, εστιάσαμε στο μέγεθος των block, το οποίο επηρέαζε το CPI.

Οι πειραματικές εκτελέσεις μας, επαλήθευσαν τις υποθέσεις μας, πως όσο μεγαλύτερο είναι το μέγεθος του block, τόσο μειώνονται τα cache misses και έτσι βελτιώνεται ο λόγος CPI. Αυτό συμβαίνει, επειδή οι επεξεργαστές επωφελούνται από την χωρική τοπικότητα των δεδομένων, τα οποία καλούνται σειριακά και από τα 3 προγράμματα (με την εξαίρεση του ProgramC.s στο οποίο γίνεται πολλαπλασιασμός πινάκων και για τον B πίνακα δεν υπάρχει χωρική τοπικότητα). Παρακάτω βρίσκονται διαγράμματα διαμόρφωσης του CPI στον οριζόντιο άξονα, όταν αλλάζουμε το μέγεθος των block:

MIPS C

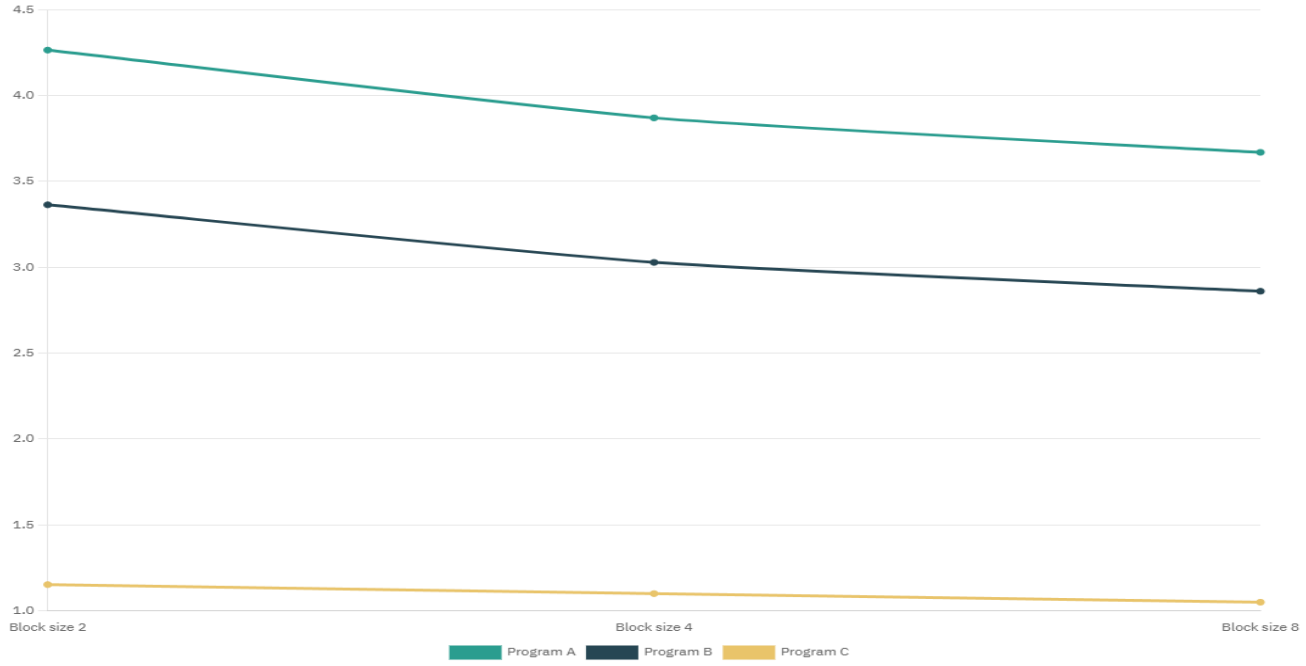


MIPS B

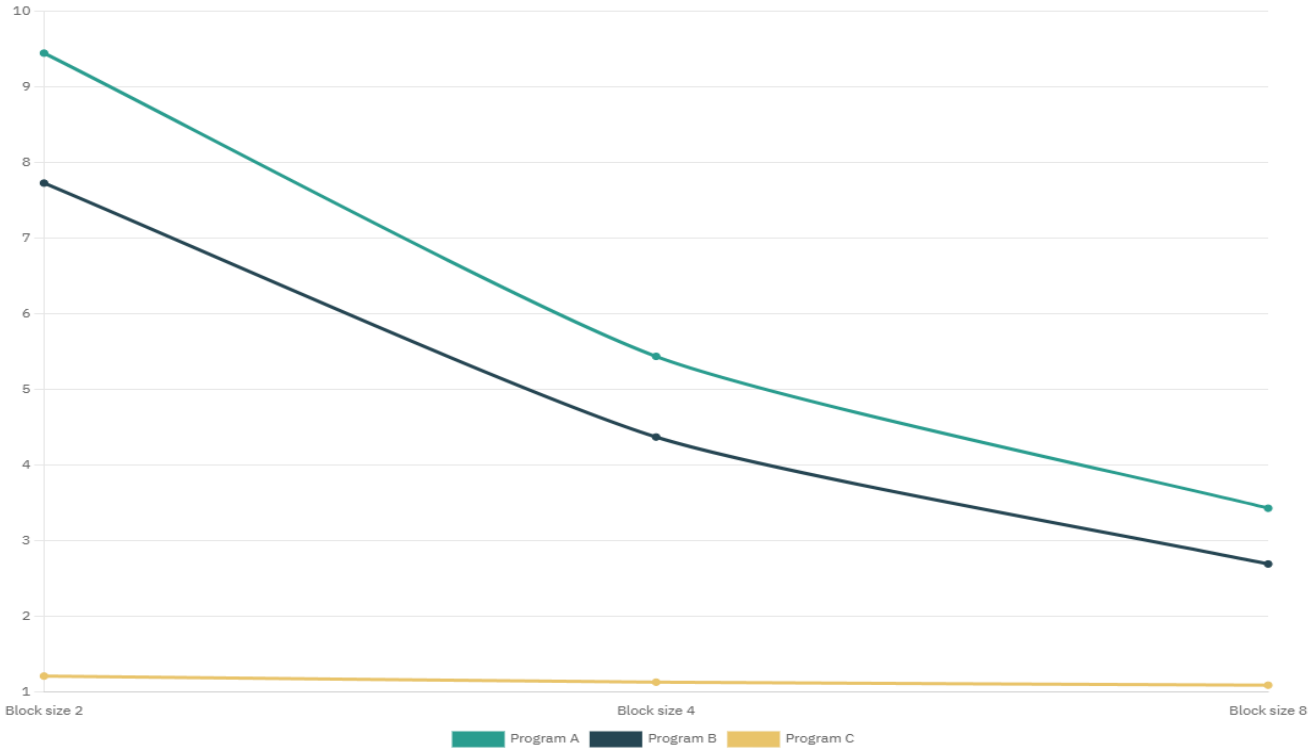


Η βελτίωση με το μέγεθος των block 8 είναι εμφανής, επομένως, προχωρώντας θέσαμε σε κάθε εκτέλεσή μας το block size = 8 και μελετήσαμε  τις εκτελέσεις των 3 προγραμάτων για τους 3 επεξεργαστές. Παρατηρήσαμε τα εξής:

## Για τον MIPS A:

Ο MIPS A έχει πολύ χαμηλό performance και πολύ υψηλό CPI, λόγω της έλλειψης cache και της καθυστέρησης 60 κύκλων κάθε φορά που θέλουμε είτε να εκτελέσουμε μία εντολή είτε να κάνουμε κάποια προσπέλαση ή γράψιμο στη μνήμη. Η ποινή των 60 κύκλων περιορίζει πολύ την απόδοση του επεξεργαστή σε κάθε πρόγραμμα καθώς αυτή εξαρτάται πλήρως από τον χρόνο που θα χρειαστεί για την πρόσβαση στην μνήμη. Παρακάτω δίνονται διαγράμματα με την απόδοση του επεξεργαστή.

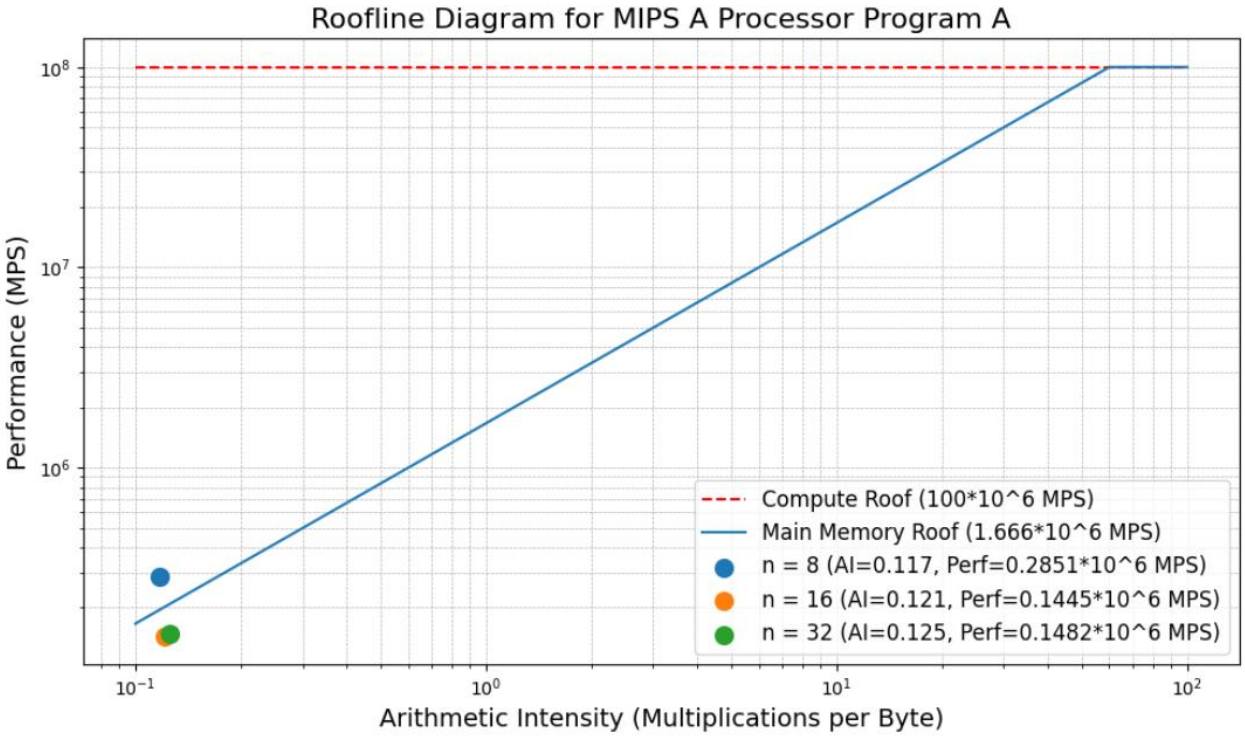


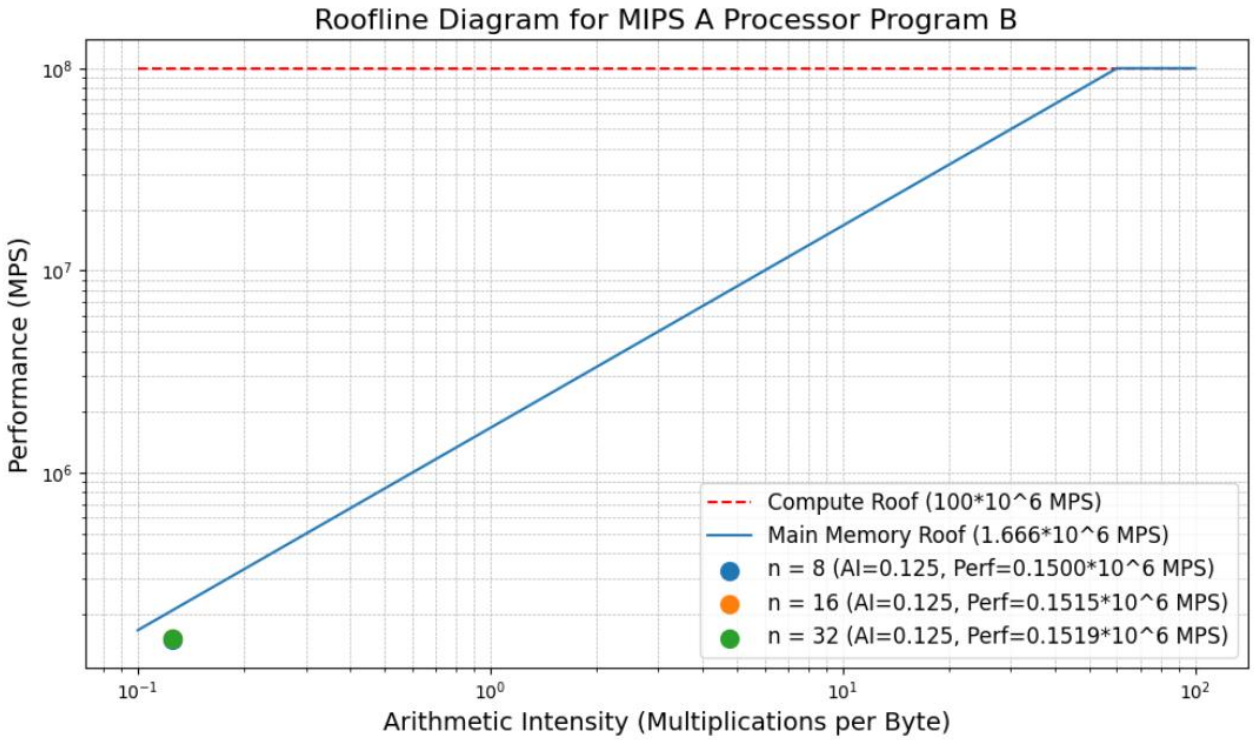

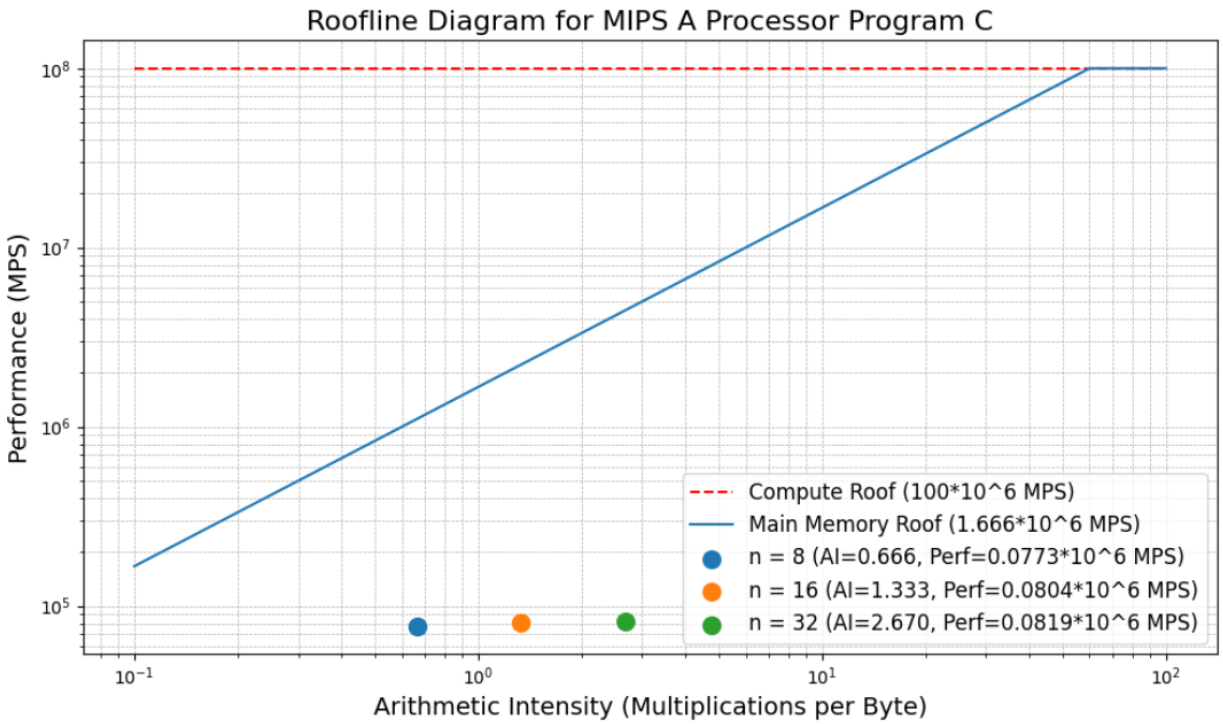


## Για τον MIPS B:

Ο MIPS B βελτιώνει πάρα πολύ τον χρόνο εκτέλεσης, λόγω της ύπαρξης της L1 program cache και της L1 data cache. Χάρη σε αυτές οι εντολές και τα δεδομένα δεν φορτώνονται πλέον 1 τη φορά με ποινή 60 κύκλων. Αντ' αυτού η ποινή αυτή μοιράζεται στην πρόσβαση σε περισσότερες λέξεις (words), συγκεκριμένα 8 (για block size 8 στο οποίο εστιάσαμε), τις οποίες είναι πολύ πιθανό να χρησιμοποιήσουμε σε επόμενους κύκλους, είτε επειδή το πρόγραμμα εκτελείται σειριακά, είτε λόγω της φύσεως των προγραμμάτων μας όπου τα δεδομένα ζητούνται με τη σειρά με την οποία βρίσκονται στη μνήμη. Επειδή επεξεργαζόμαστε πίνακες ή διανύσματα, τα δεδομένα θα είναι ακολουθιακά στη μνήμη, άρα έχουμε πολύ λιγότερα cache misses. Με βάση τη θεωρία, θα περιμέναμε η απόδοση να βελτιώνεται για μικρότερο associativity (και μεγαλύτερο set size), κυρίως για τα προγράμματα A και B όπου η προσπέλαση στη μνήμη γίνεται μόνο ακολουθιακά λόγω της μεγάλης χωρικής τοπικότητας. Παρακάτω δίνονται διαγράμματα με την απόδοση του επεξεργαστή.

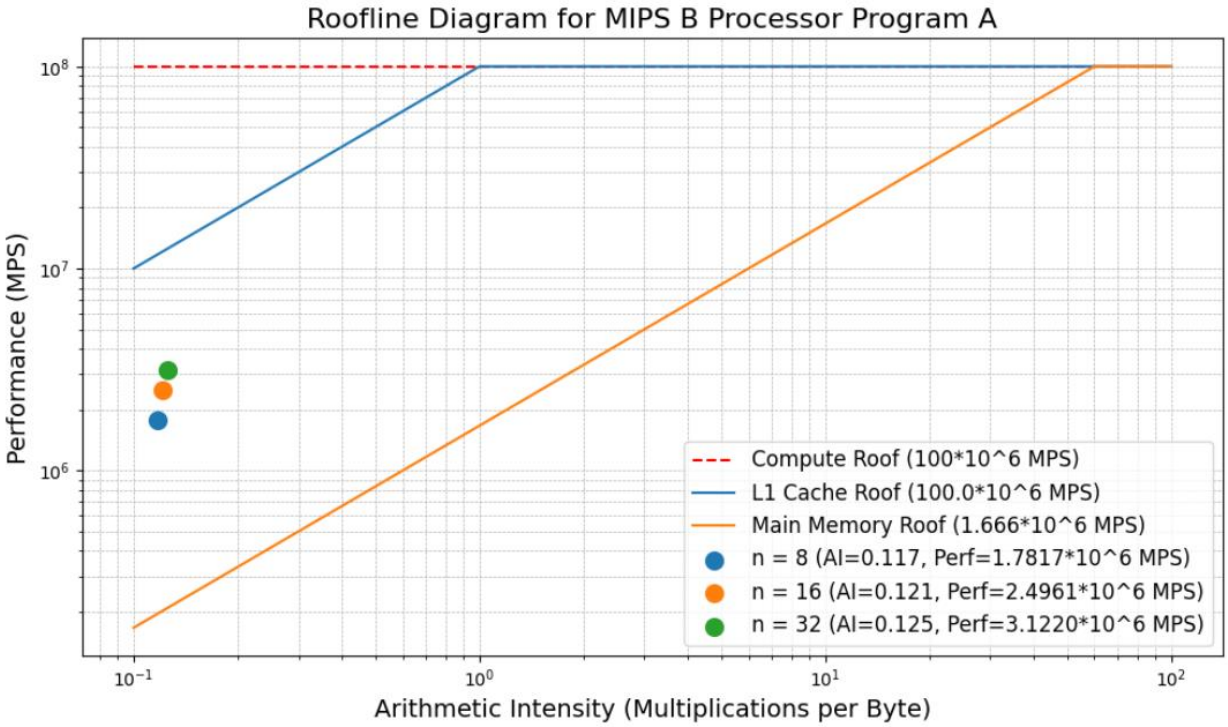
Roofline Diagram for MIPS B Processor Program A
Performance (MPS)
Arithmetic Intensity (Multiplications per Byte)
Compute Roof (100*10^6 MPS)
L1 Cache Roof (100.0*10^6 MPS)
Main Memory Roof (1.666*10^6 MPS)
n = 8 (AI=0.117, Perf=1.7817*10^6 MPS)
n = 16 (AI=0.121, Perf=2.4961*10^6 MPS)
n = 32 (AI=0.125, Perf=3.1220*10^6 MPS)

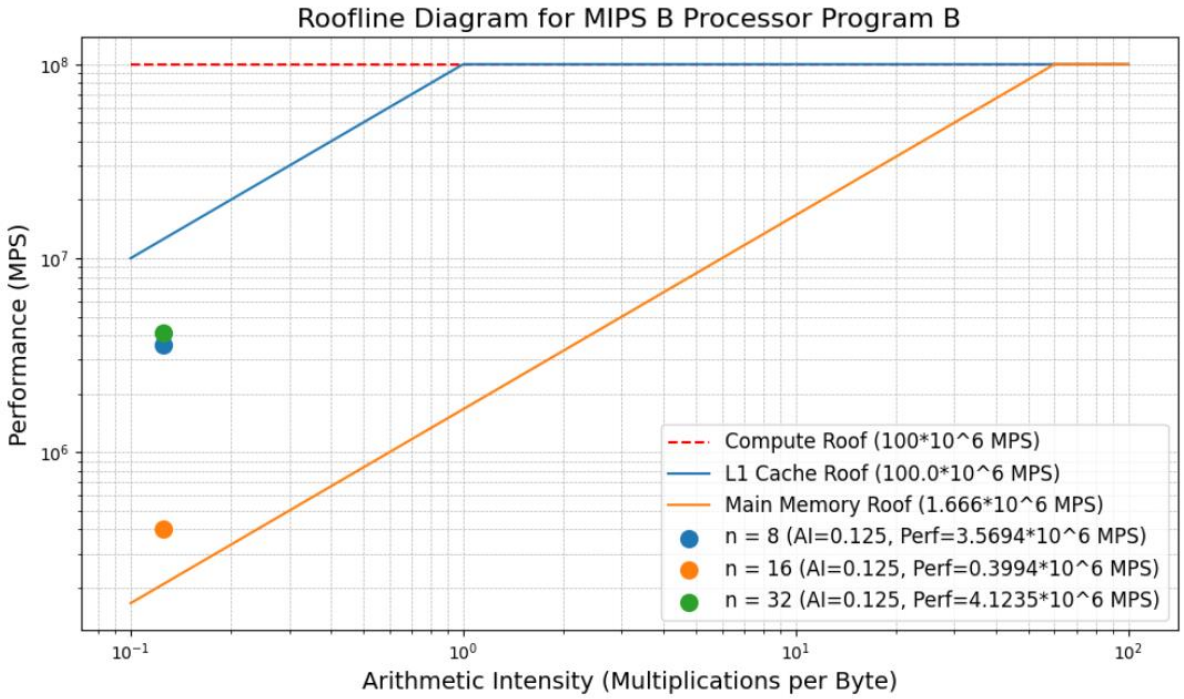
Roofline Diagram for MIPS B Processor Program B
Performance (MPS)
Arithmetic Intensity (Multiplications per Byte)
Compute Roof (100*10^6 MPS)
L1 Cache Roof (100.0*10^6 MPS)
Main Memory Roof (1.666*10^6 MPS)
n = 8 (AI=0.125, Perf=3.5694*10^6 MPS)
n = 16 (AI=0.125, Perf=0.3994*10^6 MPS)
n = 32 (AI=0.125, Perf=4.1235*10^6 MPS)

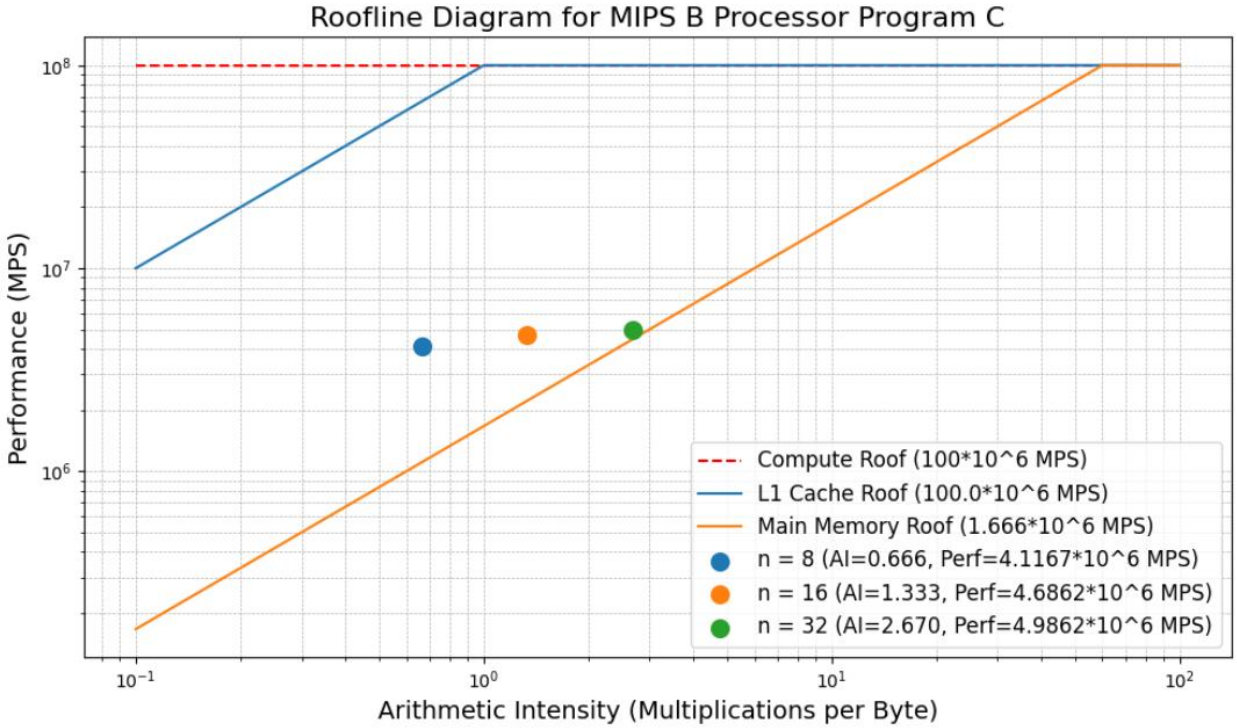


## Για τον MIPS C:

Ο MIPS C εκτός από την L1 cache για δεδομένα και εντολές, διαθέτει και L2 cache. Από τις εκτελέσεις μας είδαμε ότι η L2 cache επιβαρύνει τους χρόνους εκτέλεσεις, καθώς τα μεγέθη n = 8, 16, 32 είναι πολύ μικρά για να αναδειχθεί η χρησιμότητά της σε όλα τα προγράμματα. Ακόμη και για το πρόγραμμα C με 32x32 matrices (το οποιο ειναι και το προγραμμα με τα περισσοτερα δεδομενα), η L1 cache μόλις γεμίζει.

Η επιβάρυνση αυτή προκύπτει από το κόστος 6 επιπλέον κύκλων για κάθε φορά που πρέπει να προσπελάσουμε την κύρια μνήμη. Ειδικά για τα προγράμματα A και B όπου τα block δεν χρειάζεται να φορτωθούν δέυτερη φορά στη μνήμη, η L2 cache δεν χρησιμεύει πουθενά. Στο πρόγραμμα C, όμως όπου τα ίδια δεδομένα χρησιμοποιούνται πολλές φορές, η L2 χρησιμεύει για μεγάλες διστάσεις πινάκων . Παρακάτω δίνονται διαγράμματα με την απόδοση του επεξεργαστή.

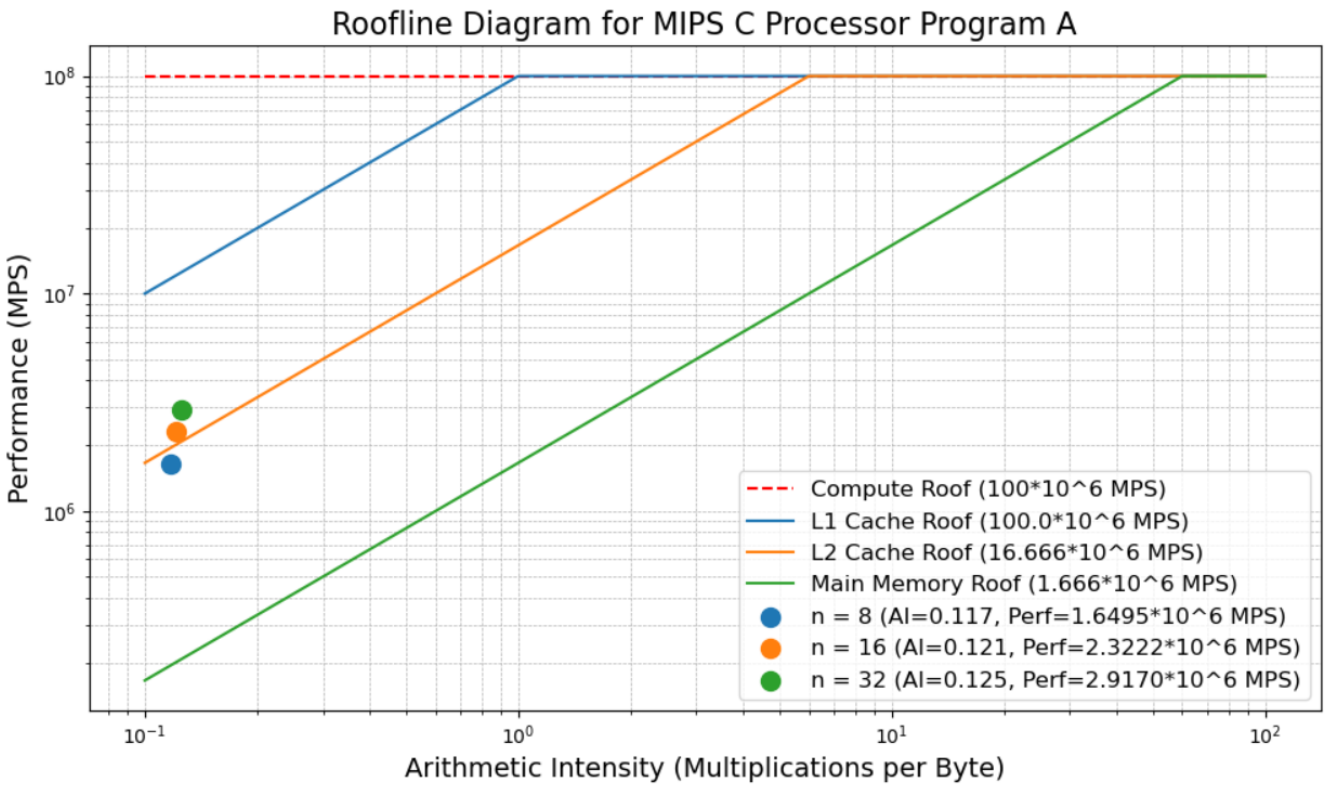
Roofline Diagram for MIPS C Processor Program A
Performance (MPS)
Arithmetic Intensity (Multiplications per Byte)
Compute Roof (100*10^6 MPS)
L1 Cache Roof (100.0*10^6 MPS)
L2 Cache Roof (16.666*10^6 MPS)
Main Memory Roof (1.666*10^6 MPS)
n = 8 (AI=0.117, Perf=1.6495*10^6 MPS)
n = 16 (AI=0.121, Perf=2.3222*10^6 MPS)
n = 32 (AI=0.125, Perf=2.9170*10^6 MPS)

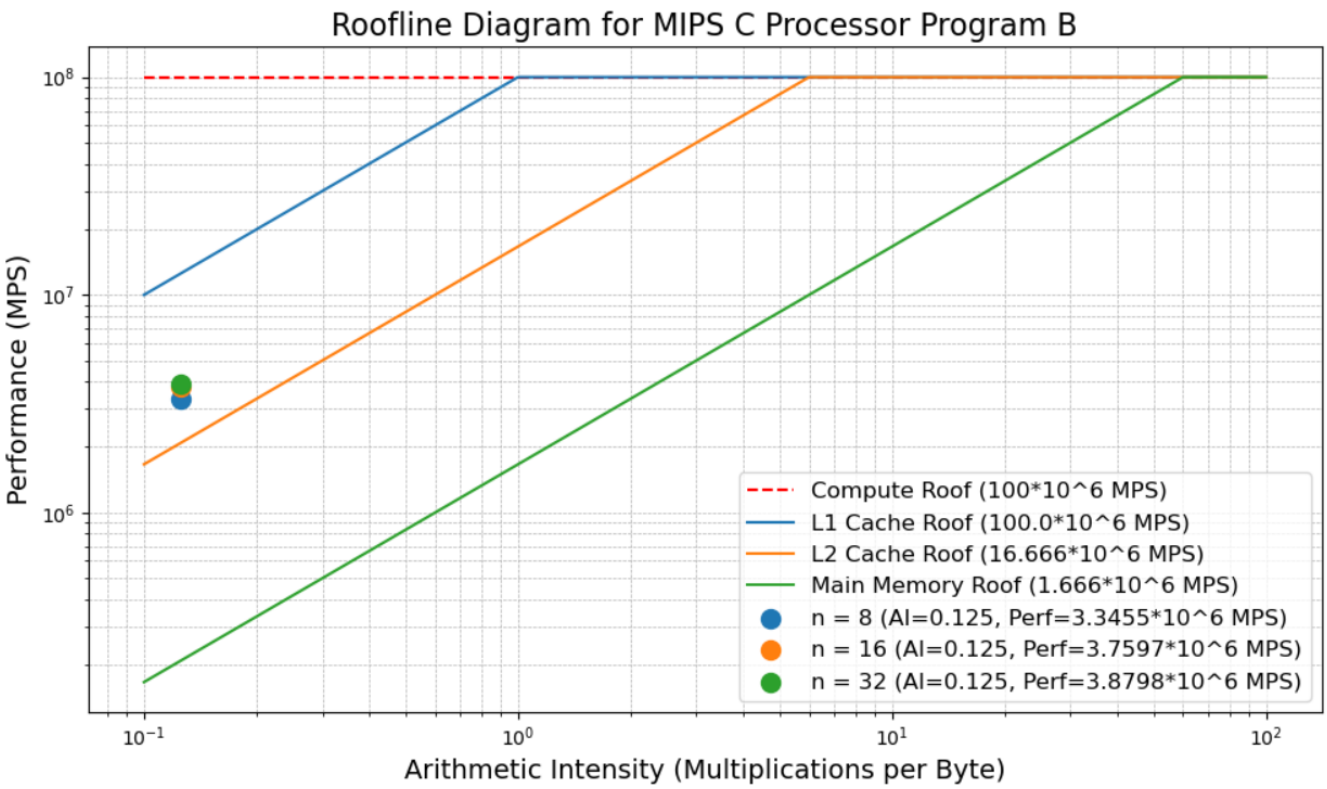
Roofline Diagram for MIPS C Processor Program B
Performance (MPS)
Arithmetic Intensity (Multiplications per Byte)
Compute Roof (100*10^6 MPS)
L1 Cache Roof (100.0*10^6 MPS)
L2 Cache Roof (16.666*10^6 MPS)
Main Memory Roof (1.666*10^6 MPS)
n = 8 (AI=0.125, Perf=3.3455*10^6 MPS)
n = 16 (AI=0.125, Perf=3.7597*10^6 MPS)
n = 32 (AI=0.125, Perf=3.8798*10^6 MPS)

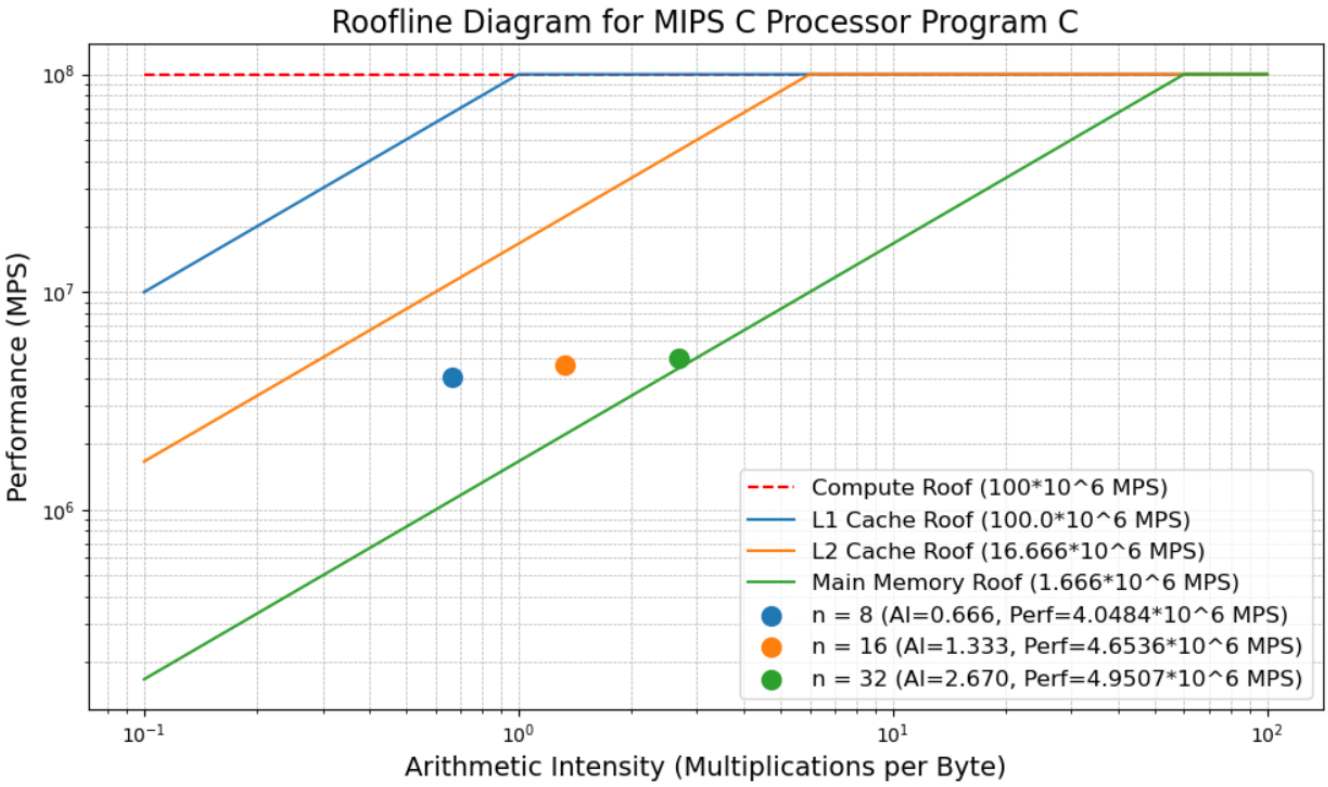


## Επισκόπηση των Roofline Diagrams και Σύνοψη:

Τα διαγράμματα Roofline αναδεικνύουν πραγματικά το πόσο περιορίζονται και τα 3 προγράμματα από την απουσία cache στον επεξεργαστή A. Η L1 cache που διαθέτει ο επεξεργαστής B βελτιώνει κατά πολύ το performance (σε πολλαπλασιασμούς ανά δευτερόλεπτο), όπως εξηγήσαμε και πιο πάνω. Τέλος, η παρουσία της L2 είναι επιβλαβής για τα προγράμματα τα οποία εξετάσαμε, καθώς δεν αξιοποιείται και επιβαρύνει μόνο το πρόγραμμα με 6 επιπλέον κύκλους ρολογιού κάθε φορά που μεταβιβάζονται δεδομένα από αυτήν. Η καλύτερη επιλογή επεξεργαστή για αυτά τα προγράμματα είναι ο **MIPS B** με **L1 Cache Block size 8**, καθώς αυτός έχει την καλύτερη απόδοση. Ο **MIPS C** θα ήταν ο καλύτερος αν το πρόγραμμα αξιοποιούσε την ύπαρξη της **L2**. Πιθανότατα, ένα πρόγραμμα με περισσότερα δεδομένα θα έτρεχε πιο γρήγορα στον **MIPS C**.